TP Fuzzy C-means : segmentation floue d'une image

Code source : `https://github.com/Harena21/tp-fcm`

1. Introduction

Objet du TP : implémentation de l'algorithme Fuzzy C-means (FCM) et application à la segmentation d'une image en régions floues, avec visualisation des degrés d'appartenance sous forme de carte de chaleur (*heatmap*).

En classification floue, chaque classe est un sous-ensemble flou, défini par une fonction d'appartenance à valeurs dans $[0, 1]$. Les régions peuvent alors se chevaucher, ce qui convient aux zones aux frontières mal définies comme les bras d'une galaxie. Une segmentation dure s'en déduit par affectation de chaque pixel à la classe de degré maximal.

2. État d'avancement

Consignes du sujet : traitées en totalité.

- Implémentation de Fuzzy C-means en Python (NumPy), validée par des tests unitaires sur les formules de l'annexe.
- Segmentation floue de l'image de la Voie lactée et visualisation par heatmap, en niveaux de gris avec $K = 2$ (cas recommandé), puis avec $K = 3$ et sur l'image couleur.

Compléments réalisés. Influence des paramètres (m, ε, initialisation), comparaison avec un k-means dur, α-coupes, accélération par histogramme (annexe A).

Non réalisé. Prise en compte du contexte spatial et essai d'autres espaces colorimétriques (section 5).

Reproductibilité. Images du sujet dans le dossier `data/` du dépôt ; production de l'ensemble des figures et des valeurs numériques par le script `experiences.py` ; tests dans `tests/test_fcm.py`.

3. Méthode

3.1 Algorithme Fuzzy C-means

FCM (Dunn 1973, Bezdek 1981) généralise k-means : au lieu d'une affectation exclusive, attribution à chaque donnée x_i d'un degré $u_{ij} \in [0, 1]$ pour chaque cluster j, sous la contrainte $\sum_j u_{ij} = 1$. L'algorithme minimise la fonction objectif $J_m = \sum_i \sum_j u_{ij}^m \|x_i - c_j\|^2$ par alternance de deux mises à jour :

$$c_j = \frac{\sum_i u_{ij}^m x_i}{\sum_i u_{ij}^m}, \qquad u_{ij} = \frac{1}{\sum_k \left(\|x_i - c_j\| / \|x_i - c_k\|\right)^{2/(m-1)}}.$$

Chaque centre est une moyenne des données pondérée par les degrés. Le degré u_{ij} dépend de la distance au centre j rapportée aux distances aux autres centres ; pour $m = 2$, il est proportionnel à $1/d_{ij}^2$, la loi en carré inverse vue en cours. Le coefficient $m > 1$ règle le degré de flou.

3.2 Mise en œuvre

Implémentation en Python avec NumPy, sans bibliothèque de clustering, afin de suivre pas à pas les étapes de l'annexe. Chaque pixel constitue une donnée, décrite par un attribut en niveaux de gris ($d = 1$) et par trois en couleur (R, G, B), soit $N \approx 10^6$ données pour une image de 1024×1024.

Initialisation par tirage aléatoire de $U^{(0)}$, puis normalisation de chaque ligne à une somme de 1. Arrêt lorsque $\max_{ij} |u_{ij}^{(k+1)} - u_{ij}^{(k)}| < \varepsilon$, critère de l'annexe. Deux précautions pratiques : remplacement des distances nulles par 10^{-10} pour éviter une division par zéro, et tri des clusters par luminosité croissante du centre, car l'ordre issu du tirage aléatoire change d'un essai à l'autre. Pour l'affichage, chaque colonne de U est remise au format de l'image ; la segmentation dure prend $\arg\max_j u_{ij}$.

3.3 Protocole expérimental

Configuration de référence : niveaux de gris, $K = 2$, $m = 2$, $\varepsilon = 0{,}01$, graine 0. Variations étudiées : $m \in \{1{,}2;\ 1{,}5;\ 2;\ 3;\ 5\}$, $\varepsilon \in \{0{,}3;\ 0{,}1;\ 0{,}01;\ 0{,}001\}$ et cinq graines d'initialisation. Indicateur de flou retenu : proportion de pixels *ambigus*, c'est-à-dire de degré maximal inférieur à 0,7.

4. Résultats

4.1 Niveaux de gris, $K = 2$

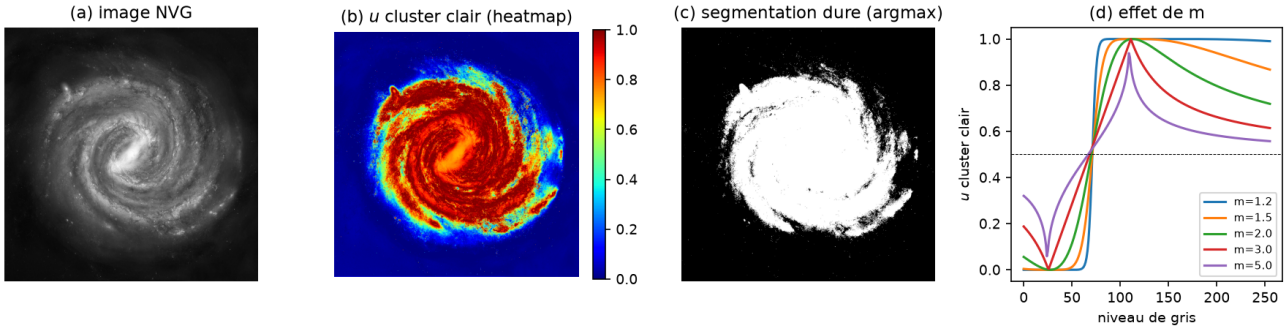


Figure 1 : (a) image d'entrée ; (b) degré d'appartenance au cluster clair ; (c) segmentation dure ; (d) degré d'appartenance au cluster clair en fonction du niveau de gris, pour plusieurs valeurs de m.

Convergence en 12 itérations (environ 3,5 s), avec une décroissance de J_m à chaque itération, de $1{,}11 \cdot 10^9$ à $4{,}65 \cdot 10^8$. Centres finaux : 27,4 pour le fond et 112,8 pour la galaxie, qui reçoit 33,5 % des pixels en segmentation dure.

Sur la heatmap (b), passage progressif du bleu au rouge le long des bras, absent de la segmentation dure (c). Les pixels ambigus représentent 8,8 % de l'image et se situent presque tous sur ces bords, là où la limite entre fond et galaxie est réellement incertaine.

Au cœur de la galaxie, zone la plus claire, le degré ne dépasse pourtant pas 0,7 environ (orange). La courbe (d) en donne la raison : un pixel à 255 est loin des deux centres ($d = 142$ et $d = 228$), d'où $u = 1/(1 + (142/228)^2) \approx 0{,}72$. Le degré mesure une proximité relative aux centres, pas une intensité, et tend vers $1/K$ pour un pixel situé au-delà de tous les centres.

Un k-means dur, écrit avec la même boucle, donne des centres de 29,1 et 112,4 en 6 itérations et une segmentation identique à celle de FCM pour 100 % des pixels. Sur cette image, FCM ne modifie donc pas la décision finale ; il y ajoute un degré de confiance par pixel.

4.2 Influence des paramètres

m	1,2	1,5	2	3	5
itérations	11	11	12	14	21
pixels avec $\max_j u_{ij} < 0{,}7$	1,5 %	4,5 %	8,8 %	18,9 %	38,6 %

Tableau 1 : Effet du coefficient de flou m (niveaux de gris, $K = 2$).

Pour $m = 1{,}2$, la courbe (d) devient presque une marche et le comportement se rapproche de k-means. Pour $m = 5$, beaucoup de pixels restent proches de 0,5 et la convergence ralentit. Les centres bougent peu (de 113,1 à 109,4 pour la galaxie). La valeur $m = 2$ de l'annexe offre ici un bon compromis.

Le critère d'arrêt demande plus d'attention. Avec $\varepsilon = 0{,}3$, valeur de l'exemple de l'annexe, l'algorithme s'arrête dès la 2e itération sur deux centres presque confondus (56,9 et 57,2) : la matrice initiale, proche de 0,5 partout, varie peu à la première mise à jour et le test passe trop tôt. Avec $\varepsilon = 0{,}1$, 0,01 et 0,001, il faut 9, 12 et 15 itérations, et les centres ne diffèrent plus que de quelques dixièmes entre 0,01 et 0,001.

Cinq graines d'initialisation différentes donnent entre 11 et 13 itérations et des centres qui varient

d'au plus 0,2. Le tirage initial a donc peu d'influence sur cette image, même si FCM ne garantit qu'un minimum local.

4.3 Trois clusters, image couleur et α-coupes

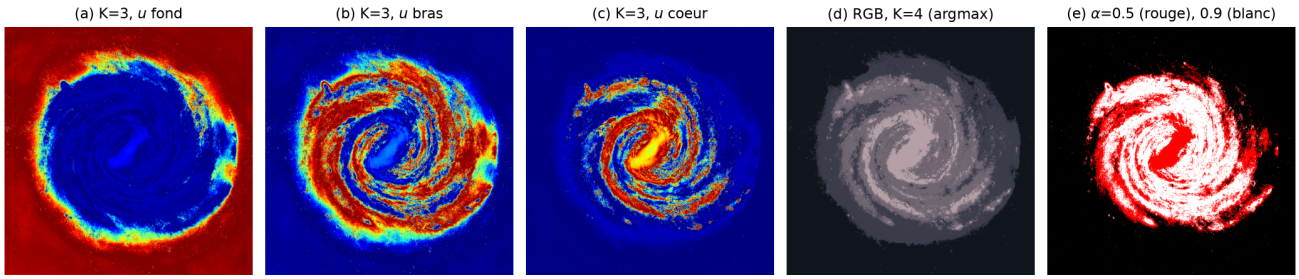


Figure 2 : (a-c) degrés d'appartenance pour $K = 3$ en niveaux de gris ; (d) segmentation couleur $K = 4$, chaque pixel prenant la couleur de son centre ; (e) deux α-coupes du cluster clair obtenu avec $K = 2$.

Avec $K = 3$, convergence en 28 itérations et centres de 22,7, 81,1 et 141,7 : le fond, les bras, puis le cœur avec les parties les plus brillantes des bras. La part de pixels ambigus monte à 15,1 %, puisqu'il y a davantage de frontières entre classes.

Sur l'image couleur avec $K = 4$, convergence en 28 itérations (environ 22 s) et centres RGB proches du gris, légèrement rosés. Le découpage ressemble beaucoup à celui des niveaux de gris : en distance euclidienne sur (R, G, B), la luminosité l'emporte, et les petites régions roses ne forment pas de cluster à elles seules.

Les α-coupes du cours s'appliquent directement à la heatmap du cluster galaxie. Celui-ci couvre 37,9 % des pixels pour $\alpha = 0{,}3$, 33,5 % pour 0,5, 29,0 % pour 0,7 et 19,6 % pour 0,9 (figure 2e). Comme dans l'exemple du chirurgien vu en cours, le choix entre une région large et les seuls pixels sûrs se fait après coup, sans relancer l'algorithme.

5. Discussion

Le traitement de chaque pixel indépendamment de ses voisins explique deux défauts visibles : les étoiles isolées du fond rejoignent la classe « galaxie », et des trous apparaissent dans les bras. Une prise en compte du voisinage, par le post-traitement contextuel du cours 1 ou par une variante spatiale de FCM, devrait lisser ces résultats.

Le nombre de clusters K reste fixé à la main. Conformément au théorème du *No Free Lunch*, aucune valeur ne convient à tous les cas : le choix dépend des structures à isoler. En couleur enfin, la distance en RGB dépend surtout de la luminosité ; un passage en Lab ou en HSV pourrait permettre d'isoler les régions roses.

6. Conclusion

Sur cette image, $m = 2$ et $\varepsilon = 0{,}01$ donnent une segmentation peu sensible au tirage initial et identique à k-means pour la décision dure. L'intérêt de FCM tient aux degrés d'appartenance, qui localisent l'incertitude sur les bords des bras et permettent de régler la taille de la région par α-coupe. Le calcul sur l'histogramme rend le cas des niveaux de gris environ 40 fois plus rapide (annexe A). La prochaine étape serait l'ajout d'un terme spatial.

Références. Supports et séances du cours (introduction à la reconnaissance des formes, sous-ensembles flous) ; sujet du TP et annexe « Fuzzy C-Means Clustering » ; J. C. Bezdek, *Pattern Recognition with Fuzzy Objective Function Algorithms*, Plenum Press, 1981.

Annexe

A. Accélération par histogramme

Une image en niveaux de gris ne comporte que 256 valeurs possibles, et le degré d'un pixel ne dépend que de sa valeur. La variante `fcm_histogramme` exécute donc FCM sur les seuls niveaux présents, pondérés par leur effectif h_l dans le calcul des centres, $c_j = \sum_l h_l u_{lj}^m x_l / \sum_l h_l u_{lj}^m$, puis reporte les degrés sur l'image.

	FCM sur les pixels	FCM sur l'histogramme
nombre de données	1 048 576	256 au plus
centres	27,44 et 112,78	27,44 et 112,78
itérations	12	10
temps de calcul	3,4 s	0,08 s

Tableau 2 : Comparaison des deux versions (niveaux de gris, $K = 2$, $m = 2$, $\varepsilon = 0{,}01$).

La segmentation dure est identique pour 100 % des pixels et les degrés diffèrent d'au plus $5 \cdot 10^{-5}$, pour un temps de calcul divisé par 40 environ. La méthode ne se transpose pas telle quelle à la couleur, où les triplets (R, G, B) distincts sont bien plus nombreux.